

---

# Análisis Comparativo de Alojamientos Airbnb: Turquía vs. Brasil :

Participates: Bruno Izaguirre, Oscar Lijeron, Raul Alvarez, Iker Marín

# Índice general

|                                                                                                                |           |
|----------------------------------------------------------------------------------------------------------------|-----------|
| <b>1. Tableau: Análisis de los Datos iniciales</b>                                                             | <b>6</b>  |
| <b>2. Clasificación de sentimientos: Análisis, Preproceso y Experimentación</b>                                | <b>14</b> |
| 2.1. Graphical Abstract de la solución . . . . .                                                               | 14        |
| 2.2. Datos . . . . .                                                                                           | 15        |
| 2.2.1. División entre Train Dev y Test de los datos para entrenar el modelo de predicción del ratings. . . . . | 15        |
| 2.2.2. Distribución de las clases en cada conjunto . . . . .                                                   | 15        |
| 2.2.3. Descripción del preproceso . . . . .                                                                    | 16        |
| 2.2.4. Primeros resultados de la tarea de clasificación (Para el 29/04/2025) . . . . .                         | 17        |
| 2.2.5. Últimos resultados de la tarea de clasificación (Para el 20/05/2025) . . . . .                          | 17        |
| 2.2.6. Descripción del Proceso de Submuestreo o Sobremuestreo . . . . .                                        | 18        |
| 2.2.7. Resultados de la aplicación de los modelos generativos . . . . .                                        | 18        |
| 2.3. Algoritmos, link a la documentación y nombre de los hiperparámetros empleados . . . . .                   | 20        |
| 2.3.1. Experimentación: Algoritmos empleados y Breve Descripción . . . . .                                     | 20        |
| 2.3.2. Resultados sobre el Development . . . . .                                                               | 21        |
| 2.3.2.1. Optimizando los resultados de la clase negativa . . . . .                                             | 21        |
| 2.3.2.2. Optimizando los resultados de la clase positiva . . . . .                                             | 21        |
| 2.3.2.3. Sin optimizar ninguna clase en particular . . . . .                                                   | 21        |
| 2.3.3. Discusión sobre el proceso de aprendizaje . . . . .                                                     | 21        |
| 2.3.4. Conclusión sobre la tarea de clasificación . . . . .                                                    | 22        |
| 2.4. Algoritmos, link a la documentación y nombre de los hiperparámetros empleados . . . . .                   | 22        |
| 2.4.1. Experimentación: Algoritmos empleados y Breve Descripción . . . . .                                     | 22        |
| 2.4.2. Resultados . . . . .                                                                                    | 22        |
| 2.4.3. Discusión sobre los descubrimientos realizados . . . . .                                                | 27        |
| <b>Bibliografía</b>                                                                                            | <b>27</b> |

# Índice de figuras

|                                                                            |    |
|----------------------------------------------------------------------------|----|
| 1.1. Media de valoraciones comparando con el competidor . . . . .          | 6  |
| 1.2. Tipos de propiedades en Turquía y su frecuencia . . . . .             | 7  |
| 1.3. Tipos de propiedades en Brasil y su frecuencia . . . . .              | 7  |
| 1.4. Media de precios comparando con el competidor . . . . .               | 8  |
| 1.5. Relación entre los precios y ratings de Turquía . . . . .             | 8  |
| 1.6. Relación entre los precios y ratings de Brasil . . . . .              | 9  |
| 1.7. Mapa Listings de Turquía . . . . .                                    | 9  |
| 1.8. Mapa Listings de Brasil . . . . .                                     | 10 |
| 1.9. Distribución de ratings en Brasil . . . . .                           | 11 |
| 1.10. Distribución de ratings en Turquía . . . . .                         | 11 |
| 1.11. Evolución de los ratings de Turquía y Brasil . . . . .               | 12 |
| 1.12. Porcentaje de cumplimiento de ratio precio/satisfacción . . . . .    | 13 |
| 2.1. Graphical Abstract . . . . .                                          | 14 |
| 2.2. Distribucion de Opiniones de Turquía y Brasil . . . . .               | 23 |
| 2.3. Porcentajes de Opiniones de Turquía y Brasil . . . . .                | 24 |
| 2.4. Nº de apariciones de 'clean' en Turquía y Brasil . . . . .            | 25 |
| 2.5. Nº de apariciones de 'host' en Turquía y Brasil . . . . .             | 25 |
| 2.6. Nº de apariciones de 'location' en Turquía y Brasil . . . . .         | 26 |
| 2.7. Nº de apariciones de palabras negativas en Turquía y Brasil . . . . . | 26 |

# Índice de cuadros

|                                                                                                               |    |
|---------------------------------------------------------------------------------------------------------------|----|
| 2.1. División Train, Dev y Test de los datos de AirBnBReviews . . . . .                                       | 15 |
| 2.2. División Train, Dev y Test de los datos de TripadvisorHotelReviews . . . . .                             | 15 |
| 2.3. Dev y Test de los datos centrales del estudio que son los contenidos en Airbnn.csv . . . . .             | 15 |
| 2.4. Distribución Train, Dev y Test de AirBnBReviews . . . . .                                                | 15 |
| 2.5. Distribución Train, Dev y Test de tripAdvisor . . . . .                                                  | 15 |
| 2.6. Resultados sobre el conjunto de desarrollo de AirBnBReviews . . . . .                                    | 17 |
| 2.7. Resultados sobre el Dev de los distintos algoritmos y alternativas tripAdvisor . . . . .                 | 17 |
| 2.8. Resultados sobre el conjunto de desarrollo de AirBnBReviews . . . . .                                    | 17 |
| 2.9. Resultados sobre el Dev de los distintos algoritmos y alternativas tripAdvisor . . . . .                 | 18 |
| 2.10. Resultados sobre el dev y el test de airbnb final. Desviación= $(predicho - medio)^2$ . . . . .         | 18 |
| 2.11. Resultados sobre el <i>dev</i> y el <i>test</i> de Airbnb. Desviación = $(predicho - real)^2$ . . . . . | 19 |
| 2.12. Resultados Clase Negativa modelo entrenado con AirBNBReviews . . . . .                                  | 21 |
| 2.13. Resultados Clase Negativa modelo entrenado con tripAdvisor_hotel_reviews . . . . .                      | 21 |
| 2.14. Resultados Clase Positiva modelo entrenado con AirBNBReviews . . . . .                                  | 21 |
| 2.15. Resultados Clase Positiva modelo entrenado con tripAdvisor_hotel_reviews . . . . .                      | 21 |
| 2.16. Resultados generales modelo entrenado con AirBNBReviews . . . . .                                       | 21 |
| 2.17. Resultados generales modelo entrenado con tripAdvisor_hotel_reviews . . . . .                           | 21 |

# Acrónimos

- **LR**: Logistic Regression
- **XGB**: XGBoost
- **MNB**: Multinomial Naive Bayes
- **BoW**: Bag of Words
- **Tf-Idf**: Term frequency – Inverse document frequency

# 1. Tableau: Análisis de los Datos iniciales

En este apartado aparecerán las comparativas de los resultados mediante los gráficos que hemos creado en Tableau. Con estos resultados podremos llegar a conclusiones y explicar algunas preguntas de las muestras de alquileres de los países seleccionados. Por ejemplo: valoraciones, precios...


¿Cuál es mi zona y cuál mi competidor?

**Nuestra zona es Turquía y la zona de nuestros competidores sería Brasil.**

¿Obtengo mejores o peores valoraciones que mi competidor?

**La media de las valoraciones según la muestra que hemos trabajado en Turquía sería de 9.24 sobre 10. En cambio, Brasil tiene una valoración de un 9.31 sobre 10. Es decir, Brasil gana respecto a Turquía por un 0.7 por ciento, aunque podemos observar que son bastante similares.**

Media de las  
valoraciones de  
Turquía y Brasil




1.1. Figura: Media de valoraciones comparando con el competidor

¿Qué tipo de listings son más significativos de mi zona y de mi competidor?


**Los listings mas significativos serían los apartamentos ya que tanto en nuestra zona (Turquía) como en la zona de nuestros competidores (Brasil) estos son el tipo de propiedad más común por mucha diferencia respecto a los otros tipos.**

Tipos de propiedades de Turquía



1.2. Figura: Tipos de propiedades en Turquía y su frecuencia

Tipos de propiedades de Brasil




1.3. Figura: Tipos de propiedades en Brasil y su frecuencia

¿Qué precios medios, que tipos de listings describen mejor a mi zona y a la de mi competidor?


La media de los precios de Turquía es de 368 euros. En cambio, Brasil tiene una media de precios de 525 euros. Comparando la media de las valoraciones y de los precios podemos observar que en Brasil (nuestro competidor) los listings son más caros que en Turquía (nuestra zona).

### Media Precios en Brasil y Turquía



1.4. Figura: Media de precios comparando con el competidor


### Relación entre precio y rating de Turquía, con línea de tendencia



1.5. Figura: Relación entre los precios y ratings de Turquía



## Relación entre precio y rating de Brasil, con línea de tendencia




1.6. Figura: Relación entre los precios y ratings de Brasil

¿Puedo representar en un mapa mis listings y los de mi competidor y están más bien centrados o existe variedad?


**Si, y podemos ver que todos están muy cerca entre sí, todos los listings de Turquía se encuentran en Estambul y todos los listings de Brasil se encuentran en Rio de Janeiro.**

## Mapa Listings Turquía



1.7. Figura: Mapa Listings de Turquía

## Mapa Listings Brasil



1.8. Figura: Mapa Listings de Brasil


¿Se correlacionan los precios con los ratings?

Podemos ver que no hay grandes diferencias en cuanto a valoraciones teniendo en cuenta el precio, aunque, de hecho, viendo las líneas de tendencias podemos entender que tanto en nuestra zona (Turquía) como en la de nuestro competidor (Brasil) cuanto más caros son los alquileres menos valoración tienen, siendo esto algo más notable en el caso de Turquía.

¿Se pueden representar en un mapa los listings y sus ratings por colores?


Si, vemos que en el mapa se muestran los puntos de cada rating y dependiendo de su valoración tendrán una tonalidad diferente. Los peor valorados tendrán un color más claro y a medida que la media vaya subiendo el color también se va volviendo más oscuro.

## Grafico de los Rating de Brasil




1.9. Figura: Distribución de ratings en Brasil

## Grafico de los Rating de Turquía



1.10. Figura: Distribución de ratings en Turquía

## Evolucion Ratings Brasil Turquia




## Nº Listings Por Año

| Países  | Fecha Review |      |      |      |      |      |      |      |
|---------|--------------|------|------|------|------|------|------|------|
|         | 2012         | 2013 | 2014 | 2015 | 2016 | 2017 | 2018 | 2019 |
| Brasil  |              | 1    | 7    | 14   | 67   | 77   | 99   | 77   |
| Turquía | 2            |      | 4    | 6    | 11   | 19   | 80   | 37   |

1.11. Figura: Evolución de los ratings de Turquía y Brasil

¿Hay diferencias relevantes con respecto a la fecha?

Salvo en 2014 y en 2015, Brasil ha tenido mejores valoraciones “ratings” en los alquileres de AirBNB respecto a Turquía. Además, hay que tener en cuenta que no hay ninguna reseña en 2012 en Brasil y en 2013 no ha habido ninguna en Turquía. Entonces, el análisis en esos años es algo ambiguo.




1.12. Figura: Porcentaje de cumplimiento de ratio precio/satisfacción

¿Qué porcentaje de nuestros listings y los de nuestro competidor superan un umbral objetivo de precio/valoración?

**El 75 por ciento de las muestras cumplen la condición de un buen ratio de precio/satisfacción en ambos lados aproximadamente. (Turquía=76.05 y Brasil=75).**

## 2. Clasificación de sentimientos: Análisis, Pre-proceso y Experimentación

### 2.1. Graphical Abstract de la solución



2.1. Figura: Graphical Abstract

A partir de dos archivos CSV, obtenemos dos modelos capaces de hacer predicciones sobre reseñas. Por un lado, el modelo A, entrenado con **AirBNBReviews.csv**, es capaz de predecir si una reseña es positiva (1) o negativa (0). Por otro lado, el modelo B, entrenado con **tripadvisor\_hotel\_reviews.csv**, asigna una puntuación a la reseña en una escala del 1 al 5.

Para obtener nuestros datasets objetivo, utilizamos varios scripts. El archivo **splitter.py** extrae del dataset central **AirBNB.csv** las reseñas de Turquía y Brasil, utilizando el atributo **location** del CSV. Posteriormente, empleamos **translator.py**, que utiliza el modelo de lenguaje **gemma3:4b** para traducir las reseñas al inglés, ya que nuestros modelos están entrenados solo con reseñas en inglés. Finalmente, con **Conversor.py** generamos un archivo CSV con el ID del listing, la fecha de la reseña y el comentario. En este proceso se eliminan aquellas reseñas que no contienen comentario, ID del alojamiento y/o fecha, así como aquellas filas cuyo contenido JSON estaba malformado.

Para generar las predicciones, procedemos de la siguiente manera. Primero, cargamos ambos modelos y preprocesamos el texto de las reseñas: convertimos todo a minúsculas, eliminamos caracteres especiales, eliminamos las *stopwords* y realizamos lematización. A continuación, calculamos la puntuación esperada de la reseña para cada modelo mediante un sumatorio que multiplica cada clase posible por su probabilidad, como se indica en la figura correspondiente. Luego, escalamos ambos valores esperados a un rango de 0 a 10 y realizamos una ponderación entre ambos para obtener una puntuación final combinada.

## 2.2. Datos

### 2.2.1. División entre Train Dev y Test de los datos para entrenar el modelo de predicción del ratings.

| Conjunto De Datos | % de instancias | Num. de instancias |
|-------------------|-----------------|--------------------|
| Train             | 75              | 343                |
| Dev               | 12,5            | 57                 |
| Test Final        | 12,5            | 58                 |

2.1. Cuadro: División Train, Dev y Test de los datos de AirBnBReviews

| Conjunto De Datos | % de instancias | Num. de instancias |
|-------------------|-----------------|--------------------|
| Train             | 75              | 21093              |
| Dev               | 12,5            | 3000               |
| Test Final        | 12,5            | 3000               |

2.2. Cuadro: División Train, Dev y Test de los datos de TripadvisorHotelReviews

| Conjunto De Datos | % de instancias | Num. de instancias |
|-------------------|-----------------|--------------------|
| Dev               | 50              | 673                |
| Test Final        | 50              | 672                |

2.3. Cuadro: Dev y Test de los datos centrales del estudio que son los contenidos en Airbnn.csv

### 2.2.2. Distribución de las clases en cada conjunto

AirBnBReviews.csv

| Conjunto De Datos | Clase Neg | Clase Pos. |
|-------------------|-----------|------------|
| Train             | 176       | 167        |
| Dev               | 23        | 34         |
| Test Final        | 30        | 28         |

2.4. Cuadro: Distribución Train, Dev y Test de AirBnBReviews

tripAdvisor\_hotel\_reviews.csv

| Conjunto De Datos | Rating 1 | Rating 2 | Rating 3 | Rating 4 | Rating 5 |
|-------------------|----------|----------|----------|----------|----------|
| Train             | 1057     | 1362     | 1643     | 4473     | 6833     |
| Dev               | 182      | 218      | 255      | 756      | 1150     |
| Test Final        | 182      | 213      | 286      | 810      | 1071     |

2.5. Cuadro: Distribución Train, Dev y Test de tripAdvisor

### 2.2.3. Descripción del preproceso

#### Estrategia empleada para generar las traducciones:

Se trabajó directamente con los datos de `airbnb.csv`. Se usó el programa `splitter.py` para seleccionar las filas de interés y generar dos archivos separados: `Turkey.csv` y `Brazil.csv`. Durante este proceso, se procesaron columnas que requerían un formato JSON válido, garantizando que no existieran ambigüedades al recorrer o analizar los datos.

Una vez separados los datos por país, se tradujeron las reseñas con el programa `translator.py`. Se observó la necesidad de traducir todas las reviews al inglés dado que los distintos comentarios eran de distintos idiomas y se necesitaba que todo estuviese en inglés dado que los modelos de clasificación fueron entrenados en inglés. Todo gestionado desde un único prompt. Se mejoró iterativamente el prompt hasta lograr una traducción lo más precisa posible. Para ello, se seleccionaron bloques de 10–20 filas para comparar visualmente las traducciones, complementando el análisis con herramientas como Google Translator y ChatGPT para validar su fidelidad.

Inicialmente se utilizó el modelo `gemma2:2b`, y posteriormente se migró a `gemma3:4b`, observándose una mejora significativa en la calidad de las traducciones.

El prompt utilizado fue el siguiente:

*Translate this review into natural, fluent English. Maintain the exact meaning, including any negative comments or criticisms. Pay special attention to:*

- 1. Preserving negations (like "not", "no", "isn't")*
- 2. Accurately translating descriptions of location, cleanliness, privacy, and noise*
- 3. Keeping all details about the host and property*
- 4. Correctly handling place names and cultural references without mistranslating them*
- 5. If the input text is extremely short (such as a single word or a name), and it does not form a complete or meaningful review on its own, do not try to interpret or expand it. Instead, return the text exactly as it was provided, without adding anything.*

*Only output the translated text with no additional commentary. Do not add any explanations, introductions, or conclusions.*

Se controló la verbosidad de la respuesta mediante la última instrucción del prompt: “Only output the translated text with no additional commentary. Do not add any explanations, introductions, or conclusions.”

#### Preproceso en clasificación:

Por otro lado, hemos convertido los textos en vectores empleando tf-idf, aunque para entrenar el modelo con el csv de tripAdvisor tuvimos que limitar el número de palabras máximas del tf-idf por problemas de rendimiento. Pasamos las palabras a minúsculas, quitamos stopwords y caracteres especiales y lematizamos.



### 2.2.4. Primeros resultados de la tarea de clasificación (Para el 29/04/2025)

| Algoritmo    | Hiperparámetros                                                                                                                      | Clase Weighted                                                    |
|--------------|--------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------|
| Naive Bayes  | alpha: 0.1, fit_prior: True                                                                                                          | F1_Score: 0.979, Accuracy: 0.979, Recall: 0.979, Precision: 0.980 |
| KNN          | algorithm: auto, leaf_size: 20, n_neighbors: 1, p: 2, weights: uniform                                                               | F1_Score: 0.973, Accuracy: 0.973, Recall: 0.973, Precision: 0.975 |
| RandomForest | bootstrap: True, criterion: entropy, max_depth: 10, max_features: log2, min_samples_leaf: 1, min_samples_split: 10, n_estimators: 50 | F1_Score: 0.944, Accuracy: 0.962, Recall: 0.962, Precision: 0.962 |

2.6. Cuadro: Resultados sobre el conjunto de desarrollo de AirBnBReviews

tripAdvisor\_hotel\_reviews.csv

| Algoritmo    | Hiperparámetros                                                                                                                  | Rating 1                                      | Rating 2                                      | Rating 3                                      | Rating 4                                      | Rating 5                                      |
|--------------|----------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------|-----------------------------------------------|-----------------------------------------------|-----------------------------------------------|-----------------------------------------------|
| Naive Bayes  | alpha: 0.1, fit_prior: false                                                                                                     | F1_Score: 0.88, Recall: 0.88, Precision: 0.88 | F1_Score: 0.26, Recall: 0.30, Precision: 0.23 | F1_Score: 0.32, Recall: 0.34, Precision: 0.30 | F1_Score: 0.51, Recall: 0.51, Precision: 0.51 | F1_Score: 0.74, Recall: 0.70, Precision: 0.77 |
| KNN          | algorithm: auto, leaf_size: 20, n_neighbors: 1, p: 2, weights: uniform                                                           | F1_Score: 0.94, Recall: 1, Precision: 0.89    | F1_Score: 0.19, Recall: 0.14, Precision: 0.27 | F1_Score: 0.20, Recall: 0.18, Precision: 0.22 | F1_Score: 0.36, Recall: 0.36, Precision: 0.36 | F1_Score: 0.61, Recall: 0.61, Precision: 0.60 |
| RandomForest | bootstrap: True, criterion: Gini, max_depth: 10, max_features: sqrt, min_samples_leaf: 1, min_samples_split: 2, n_estimators: 50 | F1_Score: 0.85, Recall: 0.99, Precision: 0.74 | F1_Score: 0, Recall: 0, Precision: 0          | F1_Score: 0, Recall: 0, Precision: 0          | F1_Score: 0.02, Recall: 0.01, Precision: 0.53 | F1_Score: 0.68, Recall: 0.94, Precision: 0.54 |

2.7. Cuadro: Resultados sobre el Dev de los distintos algoritmos y alternativas tripAdvisor

### 2.2.5. Últimos resultados de la tarea de clasificación (Para el 20/05/2025)

AirBnBReviews.csv

| Algoritmo    | Hiperparámetros                                                                                                                      | Clase Weighted                                                    |
|--------------|--------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------|
| Naive Bayes  | alpha: 0.1, fit_prior: True                                                                                                          | F1_Score: 0.979, Accuracy: 0.979, Recall: 0.979, Precision: 0.980 |
| KNN          | algorithm: auto, leaf_size: 20, n_neighbors: 1, p: 2, weights: uniform                                                               | F1_Score: 0.973, Accuracy: 0.973, Recall: 0.973, Precision: 0.975 |
| RandomForest | bootstrap: True, criterion: entropy, max_depth: 10, max_features: log2, min_samples_leaf: 1, min_samples_split: 10, n_estimators: 50 | F1_Score: 0.944, Accuracy: 0.962, Recall: 0.962, Precision: 0.962 |

2.8. Cuadro: Resultados sobre el conjunto de desarrollo de AirBnBReviews

tripAdvisor\_hotel\_reviews.csv

| Algoritmo    | Hiperparámetros                                                                                                                  | Rating 1                                      | Rating 2                                      | Rating 3                                      | Rating 4                                      | Rating 5                                      |
|--------------|----------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------|-----------------------------------------------|-----------------------------------------------|-----------------------------------------------|-----------------------------------------------|
| Naive Bayes  | alpha: 0.1, fit_prior: false                                                                                                     | F1_Score: 0.88, Recall: 0.88, Precision: 0.88 | F1_Score: 0.26, Recall: 0.30, Precision: 0.23 | F1_Score: 0.32, Recall: 0.34, Precision: 0.30 | F1_Score: 0.51, Recall: 0.51, Precision: 0.51 | F1_Score: 0.74, Recall: 0.70, Precision: 0.77 |
| KNN          | algorithm: auto, leaf_size: 20, n_neighbors: 1, p: 2, weights: uniform                                                           | F1_Score: 0.94, Recall: 1, Precision: 0.89    | F1_Score: 0.19, Recall: 0.14, Precision: 0.27 | F1_Score: 0.20, Recall: 0.18, Precision: 0.22 | F1_Score: 0.36, Recall: 0.36, Precision: 0.36 | F1_Score: 0.61, Recall: 0.61, Precision: 0.60 |
| RandomForest | bootstrap: True, criterion: Gini, max_depth: 10, max_features: sqrt, min_samples_leaf: 1, min_samples_split: 2, n_estimators: 50 | F1_Score: 0.85, Recall: 0.99, Precision: 0.74 | F1_Score: 0, Recall: 0, Precision: 0          | F1_Score: 0, Recall: 0, Precision: 0          | F1_Score: 0.02, Recall: 0.01, Precision: 0.53 | F1_Score: 0.68, Recall: 0.94, Precision: 0.54 |

2.9. Cuadro: Resultados sobre el Dev de los distintos algoritmos y alternativas tripAdvisor

tripAdvisor\_hotel\_reviews.csv

| Algoritmo   | Rating medio predicho | Rating medio real | Desviacion |
|-------------|-----------------------|-------------------|------------|
| Naive Bayes | 7,41                  | 9,27              | 3,46       |

2.10. Cuadro: Resultados sobre el dev y el test de airbnb final. Desviación= $(predicho - medio)^2$ 

### 2.2.6. Descripción del Proceso de Submuestreo o Sobremuestreo

Dado el caracter desbalanceado de las opiniones (positivas, negativas, neutras) se ha probado realizar Over y Undersampling. Al final, se ha empleado la técnica Oversampling implementada en la librería imblearn.over\_sampling, en concreto RandomOverSampler ya nos daba mejores resultados en el dev y test.

### 2.2.7. Resultados de la aplicación de los modelos generativos

#### Estrategia empleada para generar *ratings*:

Una vez generadas las traducciones, se utilizaron tres scripts: `id_date_rev.py`, `limpiar_reviews.py` y `clasificador_generativo.py`.

- `id_date_rev.py` extrae el *ID* del alojamiento, la fecha y los comentarios. Si una reseña contenía múltiples comentarios, se dividían en líneas separadas, repitiendo el *ID* correspondiente.
- `limpiar_reviews.py` eliminó líneas vacías, comentarios sin significado útil y cadenas compuestas únicamente por caracteres especiales.

Las reseñas preprocesadas se evaluaron usando `clasificador_generativo.py`, aplicando el paradigma de aprendizaje *In-Context Learning*, específicamente el **shot learning paradigm**.

#### Prompt base empleado:

You are an impartial Airbnb quality rater.  
Rate ONLY the *\*single\** review that follows on a *\*\*0-10 integer scale\*\**:

- 0 = unusable or dangerously bad
- 5 = average / acceptable
- 10 = exceptional in every aspect

Consider cleanliness, accuracy, communication, location, and value **\*\*if the review mentions them\*\***.  
**\*\*Reply with JUST one integer (no text, no period).\*\***

Se experimentó con tres variantes:

- **Zero-shot learning:** el modelo realiza la tarea sin ejemplos previos.
- **One-shot learning:** se proporciona un único ejemplo para guiar al modelo.

```
{"review": "Decent stay. Nothing special, but the location is convenient and the bed comfortable.", "rating": "7"}
```

- **Few-shot learning:** se presentan múltiples ejemplos (6 en total), que cubren un espectro de opiniones desde extremadamente negativas hasta muy positivas.

Los ejemplos del enfoque *few-shot* fueron los siguientes:

```
# 0) Extremadamente negativa
{"review": "The apartment was filthy, smelt of mold, and the host never replied to my messages.",
"rating": "1"},
# 1) Negativa
{"review": "The place was dirty and communication was terrible.", "rating": "3"},
# 2) Neutra-negativa
{"review": "It was okay overall, but the check-in was slow and the street is very noisy at night.",
"rating": "5"},
# 3) Neutra-positiva
{"review": "Decent stay. Nothing special, but the location is convenient and the bed comfortable.",
"rating": "7"},
# 4) Positiva
{"review": "Everything was clean and exactly as described. Great host and quiet neighborhood.",
"rating": "9"},
# 5) Muy positiva
{"review": "Amazing apartment! Spotless, beautifully decorated, and the host went above and beyond.
Would book again.", "rating": "10"},
```

El control de la verbosidad del modelo se mantuvo mediante la cláusula final del prompt base: *Reply with JUST one integer (no text, no period)*.

Luego, se compararon los resultados de predicción usando programas que calculan el error cuadrático medio. Esto se realiza con el ejecutable `pipeline.sh`, que invoca diferentes scripts y produce un archivo `.csv` cuya última fila contiene el valor del *Mean Squared Error (MSE)*. A este valor se le aplica la raíz cuadrada para estimar la desviación típica. Finalmente, el programa `unir.py` calcula la media real, la media predicha y la desviación cuadrática.

### Resultados obtenidos:

| Algoritmo                | Hiperparámetros                                         | Media Predicha | Media Real | Desv. |
|--------------------------|---------------------------------------------------------|----------------|------------|-------|
| shot learning: zero-shot | temperature=0,<br>num_predict=1,<br>top_k=10, top_p=0.5 | 7.72           | 9.28       | 2.45  |
| shot learning: one-shot  | temperature=0,<br>num_predict=1,<br>top_k=10, top_p=0.5 | 8.16           | 9.28       | 1.24  |
| shot learning: few-shots | temperature=0,<br>num_predict=1,<br>top_k=10, top_p=0.5 | 6.59           | 9.28       | 7.22  |

2.11. Cuadro: Resultados sobre el *dev* y el *test* de Airbnb. Desviación =  $(\text{predicho} - \text{real})^2$

**Hiperparámetros utilizados:**

- **temperature=0**  
Controla el nivel de aleatoriedad en las respuestas del modelo. Un valor de 0 implica comportamiento completamente determinista: el modelo siempre produce la misma salida para una entrada dada. Valores más altos (como 0.7 o 1) permiten más creatividad pero reducen la consistencia. Para esta tarea, se eligió 0 para asegurar estabilidad en la calificación de reseñas.
- **num\_predict=1**  
Define la cantidad de tokens que debe generar el modelo como respuesta. En este contexto, se espera únicamente un número entero (el rating), por lo que se restringe a un solo token.
- **top\_k=10**  
Limita la generación a los 10 tokens con mayor probabilidad en cada paso, reduciendo la posibilidad de respuestas inesperadas. Un valor bajo como 10 favorece salidas más predecibles.
- **top\_p=0.5**  
Implementa "nucleus sampling", permitiendo que el modelo seleccione entre tokens cuya probabilidad acumulada no exceda el 50 %. Esto introduce un nivel de diversidad controlada en la generación. Se usa junto con **top\_k** para equilibrar precisión y variabilidad.

**Análisis interpretativo:**

Los resultados evidencian que la estrategia **one-shot learning** ofreció el mejor rendimiento general, con una predicción media de 8.16 frente a la media real de 9.28 y una desviación de apenas 1.24. Esto sugiere que un solo ejemplo guía de referencia fue suficiente para alinear al modelo con los criterios de evaluación.

El enfoque **zero-shot** también se comportó de forma aceptable, aunque con una desviación mayor (2.45), posiblemente por la falta de contexto específico en la tarea.

En contraste, el **few-shot learning**, a pesar de incluir múltiples ejemplos cuidadosamente seleccionados, produjo los resultados menos precisos, con una desviación notablemente alta (7.22). Esto puede deberse a una sobresaturación de contexto o a una mala generalización del modelo frente a múltiples señales contradictorias.

Estos hallazgos sugieren que, para tareas de clasificación subjetiva con LLMs, menos contexto bien elegido puede ser más eficaz que múltiples ejemplos diversos.

## 2.3. Algoritmos, link a la documentación y nombre de los hiperparámetros empleados

### 2.3.1. Experimentación: Algoritmos empleados y Breve Descripción

Hemos empleado los siguientes algoritmos con los siguientes hiper-parámetros.

- **Multinomial Naive Bayes:**
  - Hiperparámetros: `alpha` y `fit_prior`
  - Link: Sklearn MultinomialNB
- **Random Forest:**
  - Hiperparámetros: `n_estimators`, `criterion`, `max_depth`, `min_samples_split`, `min_samples_leaf`, `max_features` y `bootstrap`.
  - Link: Sklearn RandomForest
- **kNN:**
  - Hiperparámetros: `n_neighbors`, `weights`, `algorithm`, `leaf_size` y `p`.
  - Link: Sklearn KNN

### ■ Modelos Generativos (p.e. Llama):

- Hiperparámetros: temperature, num\_predict, top\_k y top\_p
- Link: Explicación de temperature, top-k, top-p y otros hiperparámetros

## 2.3.2. Resultados sobre el Development

En esta sección se presentan los resultados obtenidos para el development.

### 2.3.2.1. Optimizando los resultados de la clase negativa

| Algoritmo   | Combinación hiperparámetros | Prec | Rec  | F-sco |
|-------------|-----------------------------|------|------|-------|
| Naive Bayes | alpha: 0.1, fit_prior: true | 0.92 | 0.96 | 0.94  |

2.12. Cuadro: Resultados Clase Negativa modelo entrenado con AirBNBReviews

| Algoritmo   | Combinación hiperparámetros   | Prec | Rec  | F-sco |
|-------------|-------------------------------|------|------|-------|
| Naive Bayes | alpha: 1e-08, fit_prior: true | 0.81 | 0.93 | 0.87  |

2.13. Cuadro: Resultados Clase Negativa modelo entrenado con tripAdvisor\_hotel\_reviews

### 2.3.2.2. Optimizando los resultados de la clase positiva

| Algoritmo   | Combinación hiperparámetros   | Prec   | Rec | F-sco  |
|-------------|-------------------------------|--------|-----|--------|
| Naive Bayes | alpha: 1e-08, fit_prior: true | 0.9714 | 1   | 0.9855 |

2.14. Cuadro: Resultados Clase Positiva modelo entrenado con AirBNBReviews

| Algoritmo   | Combinación hiperparámetros | Prec | Rec  | F-sco |
|-------------|-----------------------------|------|------|-------|
| Naive Bayes | alpha: 1, fit_prior: true   | 0.71 | 0.82 | 0.76  |

2.15. Cuadro: Resultados Clase Positiva modelo entrenado con tripAdvisor\_hotel\_reviews

### 2.3.2.3. Sin optimizar ninguna clase en particular

| Algoritmo   | Combinación hiperparámetros | Prec | Rec   | F-sco |
|-------------|-----------------------------|------|-------|-------|
| Naive Bayes | alpha: 0.1, fit_prior: true | 0.98 | 0.979 | 0.979 |

2.16. Cuadro: Resultados generales modelo entrenado con AirBNBReviews

| Algoritmo   | Combinación hiperparámetros  | Prec | Rec  | F-sco |
|-------------|------------------------------|------|------|-------|
| Naive Bayes | alpha: 0.1, fit_prior: false | 0.77 | 0.70 | 0.74  |

2.17. Cuadro: Resultados generales modelo entrenado con tripAdvisor\_hotel\_reviews

## 2.3.3. Discusión sobre el proceso de aprendizaje

Las combinaciones con  $\alpha=1e-08$  pueden indicar un nivel bajo de suavizado, que provoque más overfitting. Es posible que sea el caso de tripAdvisor\_hotel\_reviews para las clases negativas (1) y con AirBNBReviews para las positivas (1). Esto puede ser por el uso de palabras raras o más “educadas” en el entrenamiento, o quizá por la longitud de las reseñas o la frecuencia de las palabras. También podría ser por una selección inadecuada de palabras al aplicar el preproceso (lematizar, eliminar stop-words, pasar a minúsculas y eliminar caracteres extraños), y otro problema del preproceso es que por problemas de rendimiento solo disponemos de un tf-idf de 3000 palabras al entrenar con el dataset de tripAdvisor\_hotel\_reviews en vez del vocabulario completo.

Optimizar los resultados a una clase u otra no mejoró el `fscore_weighted` ni la `precision` o el `recall`, sobretodo en el caso del modelo generado a partir de `tripAdvisor_hotel_reviews`. Solo hubo mejores con respecto a las clases optimizadas.

#### 2.3.4. Conclusión sobre la tarea de clasificación

Para la optimización de los resultados sobre las clases negativa, positiva y general, se ha decidido dar mayor peso al modelo entrenado con `AirBNBReviews`, ya que ofrece mejores resultados en el conjunto de prueba final. Este modelo cuenta con una selección de palabras que permite identificar con mayor precisión las opiniones positivas, lo cual es ventajoso considerando que la media verdadera de las calificaciones es bastante alta.

En contraste, el modelo entrenado con `tripadvisor_hotel_reviews` presenta una `accuracy`, `recall` y `precision` menor del 50 % en todas las clases cuando queremos hacer alguna optimización en concreto. Mientras que sin optimizar alguna clase en el entrenamiento observamos mejores resultados en el `fscore`, `accuracy`, `precision` y `recall (weighted)`.

## 2.4. Algoritmos, link a la documentación y nombre de los hiperparámetros empleados

### 2.4.1. Experimentación: Algoritmos empleados y Breve Descripción

Creemos que deberíamos usar el algoritmo naive bayes para predecir por tener mejores resultados que el kNN y el random forest tanto en el barrido de hiperparámetros como en el test. Puede que naive bayes sea mejor para el sentimental análisis porque es eficiente y rápido con datasets de texto grandes y permite mas cantidad de palabras del tf-idf a tomar en cuenta, y porque funciona bien con datos desbalanceados gracias al suavizado.

### 2.4.2. Resultados


Antes de mostrar los resultados conviene comentar como hemos determinado que una opinión es negativa, neutra o positiva:

**Negativa:** valoración entre 0 y 5

**Neutra:** valoración entre 5 y 7

**Positiva:** valoración entre 7 y 10

## Distribucion Opiniones Brasil Turquia




2.2. Figura: Distribucion de Opiniones de Turquia y Brasil

Podemos observar que en nuestro competidores (Brasil) hay más diferencia entre el nº total de opiniones negativas y positivas, mientras que nosotros (Turquía) ,aunque tengamos también mas positivas que negativas, la diferencia no es tan amplia como en Brasil.

Esto se puede ver bien en el siguiente gráfico donde se muestran los porcentajes de cada tipo de opinión sobre el total de opiniones de cada país.

## Porcentaje de Opiniones de cada Tipo




2.3. Figura: Porcentajes de Opiniones de Turquía y Brasil

En los siguientes gráficos se muestran la cantidad de opiniones de cada tipo (positivas, neutras y negativas) en las que aparecen unas determinadas palabras que pueden ser significativas.




## Aparición de "clean"




2.4. Figura: N° de apariciones de 'clean' en Turquía y Brasil

## Aparición de "host"



2.5. Figura: N° de apariciones de 'host' en Turquía y Brasil


## Aparición de "location"



2.6. Figura: Nº de apariciones de 'location' en Turquía y Brasil

## Aparición de adjetivos y palabras negativas

(dirty, noisy, bugs...)



2.7. Figura: Nº de apariciones de palabras negativas en Turquía y Brasil

En los anteriores gráficos podemos ver, por ejemplo, que las palabras 'clean', 'host' o 'location' aparecen mayoritariamente en opiniones positivas, por lo que podemos suponer que la gente valora positivamente que los apartamentos estén limpios, que los anfitriones sean amables y que la ubicación del apartamento se encuentre en un buen sitio.

Aun así, estas palabras también aparecen (aunque en menor medida) en opiniones negativas o neutras, por lo que las personas también valoran negativamente que haya suciedad, que el trato no sea el adecuado o la mala ubicación del lugar.

En la figura 2.7 podemos ver la cantidad de apariciones de palabras y adjetivos con connotaciones negativas, tales como, 'dirty', 'small', 'noisy'... en cada tipo de opinión.

Vemos que, aunque todas las palabras por las que se ha filtrado son generalmente negativas donde más siguen apareciendo es en opiniones negativas. Esto puede deberse a que aunque los apartamentos tengan algunos problemas como que el lugar es muy ruidoso, haya bichos o que sea pequeño, estos sigan siendo en general buenos apartamentos y la gente este satisfecha con ellos porque son más las buenas cualidades de estos que las malas, aumentando así su valoración aún teniendo ciertos problemas.

### **2.4.3. Discusión sobre los descubrimientos realizados**

Tras realizar diversos gráficos para entender mejor nuestros datos, podemos concluir que nuestro competidor (Brasil) es superior en prácticamente cualquier punto respecto a nosotros (Turquía).

Vemos que aunque Brasil tenga bastantes más reviews en total que Turquía sigue quedando delante nuestro en cuanto al nº de reviews positivas respecto a su total de reviews. En nuestro caso, solamente un poco más de la mitad de las reviews (54,46 por ciento) son positivas mientras que en Brasil son más de dos tercios (71,29 por ciento).

Aún así, vemos en la figura 1.11 (Evolución de los Ratings) que en el 2014 y 2015 nuestros ratings medios fueron superiores a los de Brasil, pero a partir del 2016 hemos estado por detrás de ellos.

Uno de nuestros puntos fuertes respecto a Brasil es el precio, ya que de media nuestros apartamentos son más baratos que los de la competencia, y además, la línea de tendencia de la relación entre precio y ratings va de más a menos, lo que quiere decir que en nuestro caso, cuanto más pagas por un apartamento, peor es la valoración media que tiene. La línea de tendencia en Brasil también es descendente, pero en nuestro caso es más pronunciada.

Con esto entendemos que en Turquía no es necesario pagar mucho para estar satisfechos con nuestros apartamentos.

Por último, mencionar que Turquía también tiene un porcentaje ligeramente superior en cuanto a listings que superan el umbral precio/satisfacción, aunque es tan poca la diferencia que no es algo demasiado relevante.

## Bibliografía